



شبکه‌های عصبی مصنوعی

جلسه سیزدهم:

ماشین بردار پشتیبان (۱)

(Support Vector Machine = SVM)

ماشین بردار پشتیبان (SVM)

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱- MLP با آموزش پس انتشار خطا: از ویژگی های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می شود و بهینه بودن آن زیر سوال است.

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱– MLP با آموزش پس انتشار خطا: از ویژگی های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می شود و بهینه بودن آن زیر سوال است.

۲– RBF با آموزش دو مرحله ای (K -میانگین و RLS) که زیر بهینه است.

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱– MLP با آموزش پس انتشار خطا: از ویژگی‌های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می‌شود و بهینه‌بودن آن زیر سوال است.

۲– RBF با آموزش دو مرحله‌ای (K -میانگین و RLS) که زیربهینه است.

– در این جا، نوع دیگری از شبکه‌های پیشخورد را بررسی می‌کنیم به نام «ماشین بردار پشتیبان» (Support Vector Machine = SVM) که توسط وپنیک (Vapnik) و چروننکیس (Chervonenkis) در سال ۱۹۶۳ ابداع شد.

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱- MLP با آموزش پس انتشار خطا: از ویژگی‌های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می‌شود و بهینه‌بودن آن زیر سوال است.

۲- RBF با آموزش دو مرحله‌ای (K -میانگین و RLS) که زیر بهینه است.

– در این جا، نوع دیگری از شبکه‌های پیشخورد را بررسی می‌کنیم به نام «ماشین بردار پشتیبان» (Support Vector Machine = SVM) که توسط وپنیک (Vapnik) و چروننکیس (Chervonenkis) در سال ۱۹۶۳ ابداع شد.



ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱- MLP با آموزش پس انتشار خطا: از ویژگی‌های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می‌شود و بهینه‌بودن آن زیر سوال است.

۲- RBF با آموزش دو مرحله‌ای (K -میانگین و RLS) که زیربهینه است.

– در این جا، نوع دیگری از شبکه‌های پیشخورد را بررسی می‌کنیم به نام «ماشین بردار پشتیبان» (Support Vector Machine = SVM) که توسط وپنیک (Vapnik) و چروننکیس (Chervonenkis) در سال ۱۹۶۳ ابداع شد.

– SVM شبکه‌ای است با آموزش باینری و ویژگی‌های جالب.

ماشین بردار پشتیبان (SVM)

– دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱- MLP با آموزش پس انتشار خطا: از ویژگی‌های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می‌شود و بهینه‌بودن آن زیر سوال است.

۲- RBF با آموزش دو مرحله‌ای (K -میانگین و RLS) که زیر بهینه است.

– در این جا، نوع دیگری از شبکه‌های پیشخورد را بررسی می‌کنیم به نام «ماشین بردار پشتیبان» (Support Vector Machine = SVM) که توسط وپنیک (Vapnik) و چروننکیس (Chervonenkis) در سال ۱۹۶۳ ابداع شد.

– SVM شبکه‌ای است با آموزش باینری و ویژگی‌های جالب.

– اصول عملکرد این شبکه به مفهوم کلاسه‌بندی کردن الگوها به‌قرار زیر است:

ماشین بردار پشتیبان (SVM)

- دو دسته شبکه پیشخورد تا کنون بررسی کردیم:

۱- MLP با آموزش پس انتشار خطا: از ویژگی‌های این الگوریتم، سادگی آن است ولی الگوریتم به آهستگی همگرا می‌شود و بهینه‌بودن آن زیر سوال است.

۲- RBF با آموزش دو مرحله‌ای (K -میانگین و RLS) که زیر بهینه است.

- در این جا، نوع دیگری از شبکه‌های پیشخورد را بررسی می‌کنیم به نام «ماشین بردار پشتیبان» (Support Vector Machine = SVM) که توسط وپنیک (Vapnik) و چروننکیس (Chervonenkis) در سال ۱۹۶۳ ابداع شد.

- SVM شبکه‌ای است با آموزش باینری و ویژگی‌های جالب.

- اصول عملکرد این شبکه به مفهوم کلاسه‌بندی کردن الگوها به‌قرار زیر است:

با در دست داشتن نمونه‌های آموزش، ماشین بردار پشتیبان ابر صفحه‌ای (hyperplane) به عنوان سطح تصمیم‌گیری تشکیل می‌دهد به طوری که حاشیه جداسازی (margin of separation) بین نمونه‌های مثبت و منفی بیشینه شود.

ماشین بردار پشتیبان (SVM)

ماشین بردار پشتیبان (SVM)

– نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.

ماشین بردار پشتیبان (SVM)

- نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.
- مهم‌تر از آن این‌که بردارهای پشتیبان شامل زیرمجموعه‌ای از نقاط داده است که توسط الگوریتم آموزش استخراج می‌شود.

ماشین بردار پشتیبان (SVM)

- نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.
- مهم‌تر از آن این‌که بردارهای پشتیبان شامل زیرمجموعه‌ای از نقاط داده است که توسط الگوریتم آموزش استخراج می‌شود.
- در واقع، نام کرنل (هسته) نیز از همین جا گرفته شده است.

ماشین بردار پشتیبان (SVM)

- نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.
- مهم‌تر از آن این‌که بردارهای پشتیبان شامل زیرمجموعه‌ای از نقاط داده است که توسط الگوریتم آموزش استخراج می‌شود.
- در واقع، نام کرنل (هسته) نیز از همین جا گرفته شده است.
- برخلاف روش کرنل زیربهمینه در شبکه RBF، اصول طراحی SVM بهینه است.

ماشین بردار پشتیبان (SVM)

- نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.
- مهم‌تر از آن این‌که بردارهای پشتیبان شامل زیرمجموعه‌ای از نقاط داده است که توسط الگوریتم آموزش استخراج می‌شود.
- در واقع، نام کرنل (هسته) نیز از همین جا گرفته شده است.
- برخلاف روش کرنل زیربهمینه در شبکه RBF، اصول طراحی SVM بهمینه است.
- بهمینه‌بودن آن ریشه در بهمینه‌سازی محدب دارد.

ماشین بردار پشتیبان (SVM)

- نکته مهم در مساله آموزش بردار پشتیبان، در «کرنل ضرب داخلی» بین بردار پشتیبان و بردار x از داده‌های ورودی است.
- مهم‌تر از آن این‌که بردارهای پشتیبان شامل زیرمجموعه‌ای از نقاط داده است که توسط الگوریتم آموزش استخراج می‌شود.
- در واقع، نام کرنل (هسته) نیز از همین جا گرفته شده است.
- برخلاف روش کرنل زیربهمینه در شبکه RBF، اصول طراحی SVM بهینه است.
- بهینه‌بودن آن ریشه در بهینه‌سازی محدب دارد.
- اگرچه این ویژگی مفید، به قیمت افزایش پیچیدگی محاسبات تمام می‌شود.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$


- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$

- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.




ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$

- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.

- سطح تصمیم‌گیری (ابرصفحه) زیر را در نظر بگیرید:



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$


- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.

- سطح تصمیم‌گیری (ابرفضا) زیر را در نظر بگیرید:

بنابراین

$$\mathbf{w}^T \mathbf{x} + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x} + b < 0 \quad \text{for } d_i = -1$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$

- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.


- سطح تصمیم‌گیری (ابرصفحه) زیر را در نظر بگیرید:

بنابراین

$$\mathbf{w}^T \mathbf{x} + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x} + b < 0 \quad \text{for } d_i = -1$$

- برای \mathbf{w} و b معلوم، جداسازی بین این ابرصفحه و نزدیک‌ترین داده را «حاشیه جداسازی» نامیده و با ρ نشان می‌دهیم.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$

- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.

- سطح تصمیم‌گیری (ابرصفحه) زیر را در نظر بگیرید:


بنابراین

$$\mathbf{w}^T \mathbf{x} + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x} + b < 0 \quad \text{for } d_i = -1$$

- برای \mathbf{w} و b معلوم، جداسازی بین این ابرصفحه و نزدیک‌ترین داده را «حاشیه جداسازی» نامیده و با ρ نشان می‌دهیم.

- هدف SVM یافتن ابرصفحه‌ای است که حاشیه جداسازی (ρ) را بیشینه کند.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- داده‌های موردنظر $\{(x_i, d_i)\}_{i=1}^N$

- فرض می‌شود که الگوهای زیرمجموعه $d_i = +1$ از الگوهای زیرمجموعه $d_i = -1$ جداپذیر خطی‌اند.

- سطح تصمیم‌گیری (ابرصفحه) زیر را در نظر بگیرید:

بنابراین


$$\mathbf{w}^T \mathbf{x} + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x} + b < 0 \quad \text{for } d_i = -1$$

- برای \mathbf{w} و b معلوم، جداسازی بین این ابرصفحه و نزدیک‌ترین داده را «حاشیه جداسازی» نامیده و با ρ نشان می‌دهیم.

- هدف SVM یافتن ابرصفحه‌ای است که حاشیه جداسازی (ρ) را بیشینه کند.


- چنین سطح تصمیم‌گیری را ابرصفحه بهینه می‌نامند.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.




ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.




ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.



ماشین بردار پشتیبان (SVM)


۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.

- ضرب داخلی w و x را می توان به صورت تصویر x بر روی w در نظر گرفت.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.

- ضرب داخلی w و x را می توان به صورت تصویر x بر روی w در نظر گرفت.

- حال باید به این ضرب داخلی، مقداری اضافه کرد (پیشقدر) یا از آن کم کرد (آستانه) تا این که بردار x به طور صحیح کلاسه بندی شود.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.


- ضرب داخلی w و x را می توان به صورت تصویر x بر روی w در نظر گرفت.

- حال باید به این ضرب داخلی، مقداری اضافه کرد (پیشقدر) یا از آن کم کرد (آستانه) تا این که بردار x به طور صحیح کلاسه بندی شود.

- در نتیجه، قاعده تصمیم گیری عبارت است از:

$$w^T x + b \geq 0 \quad \text{for} \quad d_i = +1$$

$$w^T x + b < 0 \quad \text{for} \quad d_i = -1$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.

- ضرب داخلی w و x را می توان به صورت تصویر x بر روی w در نظر گرفت.


- حال باید به این ضرب داخلی، مقداری اضافه کرد (پیشقدر) یا از آن کم کرد (آستانه) تا این که بردار x به طور صحیح کلاسه بندی شود.

- در نتیجه، قاعده تصمیم گیری عبارت است از:

$$w^T x + b \geq 0 \quad \text{for} \quad d_i = +1$$

$$w^T x + b < 0 \quad \text{for} \quad d_i = -1$$

- ولی w ها و b های بسیار متفاوتی می توانند این کار انجام دهد.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- این ضرب داخلی در تشکیل ابرصفحه را از دیدگاه متفاوتی بررسی می کنیم.

بردار w را در نظر بگیرید که عمود بر ابرصفحه است.

بردار x از مجموعه داده ها را نیز در نظر بگیرید.

- ضرب داخلی w و x را می توان به صورت تصویر x بر روی w در نظر گرفت.

- حال باید به این ضرب داخلی، مقداری اضافه کرد (پیشقدر) یا از آن کم کرد (آستانه) تا این که بردار x به طور صحیح کلاسه بندی شود.


- در نتیجه، قاعده تصمیم گیری عبارت است از:

$$w^T x + b \geq 0 \quad \text{for} \quad d_i = +1$$

$$w^T x + b < 0 \quad \text{for} \quad d_i = -1$$

- ولی w ها و b های بسیار متفاوتی می توانند این کار انجام دهد.

- به دنبال مقادیر بهینه برای w و b هستیم که حاشیه جداسازی را بیشینه کند.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله عبارت است از یافتن پارامترهای w_o و b_o برای ابرصفحه بهینه
با توجه به مجموعه آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله عبارت است از یافتن پارامترهای w_o و b_o برای ابرصفحه بهینه با توجه به مجموعه آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$.

- بنابراین، ابرصفحه بهینه عبارت است از:

$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

ماشین بردار پشتیبان (SVM)


۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله عبارت است از یافتن پارامترهای w_o و b_o برای ابرصفحه بهینه با توجه به مجموعه آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$.

- بنابراین، ابرصفحه بهینه عبارت است از:

$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

- اکنون داده مشخص \mathbf{x}_i را در نظر بگیرید که کلاس آن را می دانیم.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله عبارت است از یافتن پارامترهای w_o و b_o برای ابرصفحه بهینه با توجه به مجموعه آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$.

- بنابراین، ابرصفحه بهینه عبارت است از:


$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

- اکنون داده مشخص \mathbf{x}_i را در نظر بگیرید که کلاس آن را می دانیم.

- بدون در نظر گرفتن حاشیه جداسازی، باید رابطه زیر برای \mathbf{x}_i برقرار باشد:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b < 0 \quad \text{for } d_i = -1$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله عبارت است از یافتن پارامترهای w_o و b_o برای ابرصفحه بهینه با توجه به مجموعه آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$.

- بنابراین، ابرصفحه بهینه عبارت است از:

$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

- اکنون داده مشخص \mathbf{x}_i را در نظر بگیرید که کلاس آن را می دانیم.

- بدون در نظر گرفتن حاشیه جداسازی، باید رابطه زیر برای \mathbf{x}_i برقرار باشد:


$$\mathbf{w}^T \mathbf{x}_i + b \geq 0 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b < 0 \quad \text{for } d_i = -1$$

- لیکن با در نظر گرفتن حاشیه جداسازی، و با توجه به این که می توان بردارها را نرمال کرد، رابطه زیر برای کلاسه بندی \mathbf{x}_i می توان نوشت:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

- در نتیجه:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0 \quad \text{for } i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

- در نتیجه:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0 \quad \text{for } i = 1, \dots, N$$


- برای داده هایی که بر روی حاشیه جداسازی قرار می گیرند

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.




- دو الگوی x_i^- و x_i^+ که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.




- دو الگوی \mathbf{x}_i^+ و \mathbf{x}_i^- که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.



- دو الگوی x_i^- و x_i^+ که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با $(x_i^+ - x_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده w ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی \mathbf{x}_i^+ و \mathbf{x}_i^- که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده \mathbf{w} ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- از قبل داشتیم:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- از قبل داشتیم:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- بنابراین، برای داده‌هایی که بر روی حاشیه قرار گرفته‌اند

$$\mathbf{w}^T \mathbf{x}_i^+ = 1 - b$$

$$\mathbf{w}^T \mathbf{x}_i^- = -1 - b$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- از قبل داشتیم: $\mathbf{w}^T \mathbf{x}_i + b \geq 1$ for $d_i = +1$

$\mathbf{w}^T \mathbf{x}_i + b \leq -1$ for $d_i = -1$

- بنابراین، برای داده‌هایی که بر روی حاشیه قرار گرفته‌اند

$$\mathbf{w}^T \mathbf{x}_i^+ = 1 - b$$

$$\mathbf{w}^T \mathbf{x}_i^- = -1 - b$$

- در نتیجه

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- از قبل داشتیم:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$


- بنابراین، برای داده‌هایی که بر روی حاشیه قرار گرفته‌اند

$$\mathbf{w}^T \mathbf{x}_i^+ = 1 - b$$

$$\mathbf{w}^T \mathbf{x}_i^- = -1 - b$$

- در نتیجه

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

$$\text{width} = (1 - b + 1 + b) \frac{1}{\|\mathbf{w}\|}$$


ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- از قبل داشتیم:

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$


- بنابراین، برای داده‌هایی که بر روی حاشیه قرار گرفته‌اند

$$\mathbf{w}^T \mathbf{x}_i^+ = 1 - b$$

$$\mathbf{w}^T \mathbf{x}_i^- = -1 - b$$

- در نتیجه

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

$$\text{width} = (1 - b + 1 + b) \frac{1}{\|\mathbf{w}\|}$$


- و در نهایت

$$\text{width} = \frac{2}{\|\mathbf{w}\|}$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\|$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی
معادل است با کمینه سازی اندازه بردار \mathbf{w} .

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی
معادل است با کمینه سازی اندازه بردار \mathbf{w} .

- به طور خلاصه:

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی
معادل است با کمینه سازی اندازه بردار \mathbf{w} .

- به طور خلاصه:

• ابر صفحه بهینه $\mathbf{w}_o^T \mathbf{x} + b_o = 0$ همواره برای داده های مورد نظر، یکتا است.

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی
معادل است با کمینه سازی اندازه بردار \mathbf{w} .

- به طور خلاصه:

- ابر صفحه بهینه $\mathbf{w}_o^T \mathbf{x} + b_o = 0$ همواره برای داده های مورد نظر، یکتا است.
- یعنی بردار بهینه \mathbf{w}_o ، بیشترین جداسازی ممکن را بین نمونه های مثبت و منفی به دست می دهد.

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

- با حذف ضریب ۲

$$\text{width} = \frac{1}{\|\mathbf{w}\|}$$

- بیشینه کردن رابطه فوق معادل است با کمینه کردن اندازه بردار \mathbf{w}

$$\min \|\mathbf{w}\| \Rightarrow \min \frac{1}{2} \|\mathbf{w}\|^2 \Rightarrow \boxed{\min \frac{1}{2} \mathbf{w}^T \mathbf{w}}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی معادل است با کمینه سازی اندازه بردار \mathbf{w} .

- به طور خلاصه:

- ابر صفحه بهینه $\mathbf{w}_o^T \mathbf{x} + b_o = 0$ همواره برای داده های مورد نظر، یکتا است.
- یعنی بردار بهینه \mathbf{w}_o ، بیشترین جداسازی ممکن را بین نمونه های مثبت و منفی به دست می دهد.
- این بهینگی با کمینه کردن اندازه بردار \mathbf{w} حاصل می شود.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for} \quad i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

– به این نوع مساله بهینه‌سازی مقید، «مساله اولیه» (Primal Problem) می‌گویند که به شکل زیر مشخص می‌شود:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

– به این نوع مساله بهینه‌سازی مقید، «مساله اولیه» (Primal Problem) می‌گویند که به شکل زیر مشخص می‌شود:

• تابع هزینه، تابعی محدب از بردار \mathbf{w} است.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

– بنابراین، مساله بهینه‌سازی مقید به صورت زیر بیان می‌شود:

برای داده‌های موجود $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ مطلوب است یافتن مقدار بهینه برای \mathbf{w}_o و b_o به طوری که تابع هزینه و قید زیر برآورده شوند:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

– به این نوع مساله بهینه‌سازی مقید، «مساله اولیه» (Primal Problem) می‌گویند که به شکل زیر مشخص می‌شود:

- تابع هزینه، تابعی محدب از بردار \mathbf{w} است.
- قیود، برحسب \mathbf{w} خطی‌اند.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه‌سازی مقید با استفاده از روش لاگرانژ حل می‌شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه‌سازی مقید با استفاده از روش لاگرانژ حل می‌شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).

- یعنی تابع هزینه باید نسبت به \mathbf{w} و b کمینه شود ولی نسبت به α بیشینه شود.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).


- یعنی تابع هزینه باید نسبت به \mathbf{w} و b کمینه شود ولی نسبت به α بیشینه شود.

- این مساله باعث به وجود آمدن نقطه زینی (Saddle Point) می شود.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$




- نقطه زینی تابع لاگرانژ بالا، نقطه‌ای است با ریشه‌های حقیقی ولی علامت مخالف.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$



- نقطه زینی تابع لاگرانژ بالا، نقطه‌ای است با ریشه‌های حقیقی ولی علامت مخالف.
- یک چنین تکینگی همواره ناپایدار است.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار \mathbf{w} یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار \mathbf{w} یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار \mathbf{w} یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

- به عبارت دیگر، فقط ضرایبی که دقیقا شرط $\alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$ را برآورده می کنند، می توانند مقدار غیر صفر داشته باشند.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به \mathbf{w} و b مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار \mathbf{w} یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

- به عبارت دیگر، فقط ضرایبی که دقیقا شرط $\alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$ را برآورده می کنند، می توانند مقدار غیر صفر داشته باشند.

- این شروط را شروط کاروش-کان-تاکر (Karush-Kahn-Tucker = KKT) می نامند.

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

$$\mathbf{w} = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \quad \sum_{i=1}^N \alpha_i d_i = 0$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

$$\mathbf{w} = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \quad \sum_{i=1}^N \alpha_i d_i = 0$$

- با قراردادن دو شرط اخیر در تابع لاگرانژ، نتیجه می شود:

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right) - \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right) - \sum_{i=1}^N \alpha_i d_i b + \sum_{i=1}^N \alpha_i$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

$$\mathbf{w} = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \quad \sum_{i=1}^N \alpha_i d_i = 0$$

- با قراردادن دو شرط اخیر در تابع لاگرانژ، نتیجه می شود:

$$\begin{aligned} J(\mathbf{w}, b, \alpha) &= \frac{1}{2} \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right) \\ &\quad - \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \right) - \sum_{i=1}^N \alpha_i d_i b + \sum_{i=1}^N \alpha_i \end{aligned}$$

- بعد از خلاصه سازی:

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده، تابعی است از ضرب داخلی بردارهای ورودی.

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده، تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده، تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

$$\mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده، تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\begin{aligned} \mathbf{w}_o^T \mathbf{x} + b_o = 0 \\ \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \end{aligned} \Rightarrow \begin{aligned} \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &\geq 0 & \text{for } d_i = +1 \\ \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &< 0 & \text{for } d_i = -1 \end{aligned}$$

ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده، تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\begin{aligned} \mathbf{w}_o^T \mathbf{x} + b_o = 0 \\ \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \end{aligned} \Rightarrow \begin{aligned} \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &\geq 0 \quad \text{for } d_i = +1 \\ \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &< 0 \quad \text{for } d_i = -1 \end{aligned}$$