



# شبکه‌های عصبی مصنوعی

---


جلسه چهاردهم:

ماشین بردار پشتیبان (۲)

(Support Vector Machine = SVM)

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی




$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی



$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$


$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی



$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:


$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

- در نتیجه:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0 \quad \text{for } i = 1, \dots, N$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی



$$\mathbf{w}^T \mathbf{x}_i + b \geq 1 \quad \text{for } d_i = +1$$

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1 \quad \text{for } d_i = -1$$

- این دو شرط را می توان در قالب یک شرط به این فرم نوشت:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

- در نتیجه:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0 \quad \text{for } i = 1, \dots, N$$


- برای داده هایی که بر روی حاشیه جداسازی قرار می گیرند

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.




# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $x_i^+$  و  $x_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.




# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $x_i^+$  و  $x_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با  $(x_i^+ - x_i^-)$





# ماشین بردار پشتیبان (SVM)


۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $x_i^+$  و  $x_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با  $(x_i^+ - x_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده  $w$  ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $\mathbf{x}_i^+$  و  $\mathbf{x}_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با  $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده  $\mathbf{w}$  ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.


- دو الگوی  $\mathbf{x}_i^+$  و  $\mathbf{x}_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با  $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده  $\mathbf{w}$  ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

$$\text{width} = \frac{2}{\|\mathbf{w}\|}$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $\mathbf{x}_i^+$  و  $\mathbf{x}_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.


- تفاضل این دو بردار برابر است با  $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$

- چنانچه این تفاضل را در بردار نرمال شده  $\mathbf{w}$  ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

$$\text{width} = \frac{2}{\|\mathbf{w}\|}$$

$$\min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- به خاطر بیاورید که مساله بهینه‌سازی عبارت بود از کلاسه‌بندی الگوها به طوری که حاشیه جداسازی بیشینه شود.

- دو الگوی  $\mathbf{x}_i^+$  و  $\mathbf{x}_i^-$  که بر روی حاشیه جداسازی قرار دارند، را در نظر بگیرید.

- تفاضل این دو بردار برابر است با  $(\mathbf{x}_i^+ - \mathbf{x}_i^-)$


- چنانچه این تفاضل را در بردار نرمال شده  $\mathbf{w}$  ضرب داخلی کنیم، عرض این حاشیه جداسازی به دست می‌آید:

$$\text{width} = (\mathbf{x}_i^+ - \mathbf{x}_i^-)^T \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

$$\text{width} = \frac{2}{\|\mathbf{w}\|}$$

بیشینه کردن حاشیه جداسازی بین الگوهای مثبت و منفی معادل است با کمینه‌سازی اندازه بردار  $\mathbf{w}$ .

$$\min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه‌سازی مقید با استفاده از روش لاگرانژ حل می‌شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).

- یعنی تابع هزینه باید نسبت به  $\mathbf{w}$  و  $b$  کمینه شود ولی نسبت به  $\alpha$  بیشینه شود.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- مساله بهینه سازی مقید با استفاده از روش لاگرانژ حل می شود:

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- توجه شود که جمله اول تابع لاگرانژ باید کمینه شود. ولی جمله دوم باید بیشینه شود (بیشینه کردن حاشیه جداسازی یا همان عرض خیابان).

- یعنی تابع هزینه باید نسبت به  $\mathbf{w}$  و  $b$  کمینه شود ولی نسبت به  $\alpha$  بیشینه شود.

- این مساله باعث به وجود آمدن نقطه زینی (Saddle Point) می شود.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار  $\mathbf{w}$  یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار  $\mathbf{w}$  یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار  $\mathbf{w}$  یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

- به عبارت دیگر، فقط ضرایبی که دقیقا شرط  $\alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$  را برآورده می کنند، می توانند مقدار غیر صفر داشته باشند.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

- فعلا از تابع لاگرانژ نسبت به  $\mathbf{w}$  و  $b$  مشتق گرفته و برابر صفر قرار می دهیم:

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \alpha_i d_i = 0$$

- اگرچه جواب بردار  $\mathbf{w}$  یکتا است (برطبق محدب بودن لاگرانژ) ولی در مورد آلفا نمی توان چنین مطلبی را گفت.

- بنابراین، برای شروطی که تساوی آن ها برآورده نمی شود، باید آلفای نظیر را برابر صفر قرارداد.

- به عبارت دیگر، فقط ضرایبی که دقیقا شرط  $\alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$  را برآورده می کنند، می توانند مقدار غیر صفر داشته باشند.

- این شروط را شروط کاروش-کان-تاکر (Karush-Kahn-Tucker = KKT) می نامند.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده تابعی است از ضرب داخلی بردارهای ورودی.

# ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

# ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\mathbf{w}_o^T \mathbf{x} + b_o = 0$$

$$\mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

# ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\begin{aligned} \mathbf{w}_o^T \mathbf{x} + b_o = 0 \\ \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i \end{aligned} \Rightarrow \begin{aligned} \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &\geq 0 & \text{for } d_i = +1 \\ \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b &< 0 & \text{for } d_i = -1 \end{aligned}$$



# ماشین بردار پشتیبان (SVM)

۱- ابر صفحه بهینه برای الگوهای جداپذیر خطی

$$J(\mathbf{w}, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- نکته بسیار مهم: تابع لاگرانژ بهینه شده تابعی است از ضرب داخلی بردارهای ورودی.

- در مورد ابر صفحه بهینه نیز می توان همین امر را مشاهده کرد:

$$\begin{aligned} \mathbf{w}_o^T \mathbf{x} + b_o = 0 & \Rightarrow \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b \geq 0 \quad \text{for } d_i = +1 \\ \mathbf{w}_o = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i & \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i^T \mathbf{x} + b < 0 \quad \text{for } d_i = -1 \end{aligned}$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای بهینه سازی نسبت به ضرایب لاگرانژ از «مساله دوگان» (Dual Problem) استفاده می شود.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای بهینه‌سازی نسبت به ضرایب لاگرانژ از «مساله دوگان» (Dual Problem) استفاده می‌شود.

- مساله دوگان همان جواب بهینه مساله اولیه را دارد ولی در آن جواب ضرایب لاگرانژ نیز بهینه است.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای بهینه‌سازی نسبت به ضرایب لاگرانژ از «مساله دوگان» (Dual Problem) استفاده می‌شود.

- مساله دوگان همان جواب بهینه مساله اولیه را دارد ولی در آن جواب ضرایب لاگرانژ نیز بهینه است.

- قضیه دوگانگی (Duality Theorem) به شکل زیر بیان می‌شود:

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای بهینه سازی نسبت به ضرایب لاگرانژ از «مساله دوگان» (Dual Problem) استفاده می شود.

- مساله دوگان همان جواب بهینه مساله اولیه را دارد ولی در آن جواب ضرایب لاگرانژ نیز بهینه است.

- قضیه دوگانگی (Duality Theorem) به شکل زیر بیان می شود:

آ- اگر مساله اولیه دارای جواب بهینه باشد، مساله دوگان نیز جواب بهینه دارد و مقادیر بهینه نظیر برابراند.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای بهینه سازی نسبت به ضرایب لاگرانژ از «مساله دوگان» (Dual Problem) استفاده می شود.

- مساله دوگان همان جواب بهینه مساله اولیه را دارد ولی در آن جواب ضرایب لاگرانژ نیز بهینه است.

- قضیه دوگانگی (Duality Theorem) به شکل زیر بیان می شود:

آ- اگر مساله اولیه دارای جواب بهینه باشد، مساله دوگان نیز جواب بهینه دارد و مقادیر بهینه نظیر برابراند.

ب- به منظور این که  $w_o$  جواب بهینه اولیه باشد و  $\alpha_i$  جواب بهینه دوگان، لازم و کافی است که  $w_o$  برای مساله اولیه شدنی (feasible) باشد و

$$\phi(w_o) = J(w_o, b_o, \alpha_o) = \min_w (w, b, \alpha)$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای یافتن  $\alpha_i$  های بهینه، تابع هزینه بهینه شده بر حسب  $w$  و  $b$  را در نظر بگیرید

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای یافتن  $\alpha_i$  های بهینه، تابع هزینه بهینه شده بر حسب  $w$  و  $b$  را در نظر بگیرید

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- مساله دوگان:

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای یافتن  $\alpha_i$  های بهینه، تابع هزینه بهینه شده بر حسب  $w$  و  $b$  را در نظر بگیرید

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- مساله دوگان:

با توجه به داده‌های  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  به طوری که تابع هزینه بالا را بیشینه کند، با توجه به قیود زیر:

$$\begin{aligned} \sum_{i=1}^N \alpha_i d_i &= 0 \\ \alpha_i &\geq 0 \quad i = 1, \dots, N \end{aligned}$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای یافتن  $\alpha_i$  های بهینه، تابع هزینه بهینه شده بر حسب  $w$  و  $b$  را در نظر بگیرید

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- مساله دوگان:

با توجه به داده‌های  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  به طوری که تابع هزینه بالا را بیشینه کند، با توجه به قیود زیر:

$$\begin{aligned} \sum_{i=1}^N \alpha_i d_i &= 0 \\ \alpha_i &\geq 0 \quad i = 1, \dots, N \end{aligned}$$

- توجه کنید که برخلاف مساله بهینه‌سازی اولیه که بر مبنای تابع لاگرانژ بود، مساله دوگان کاملاً بر حسب داده‌های آموزش است.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- برای یافتن  $\alpha_i$  های بهینه، تابع هزینه بهینه شده بر حسب  $w$  و  $b$  را در نظر بگیرید

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

- مساله دوگان:

با توجه به داده های  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  به طوری که تابع هزینه بالا را بیشینه کند، با توجه به قیود زیر:

$$\begin{aligned} \sum_{i=1}^N \alpha_i d_i &= 0 \\ \alpha_i &\geq 0 \quad i = 1, \dots, N \end{aligned}$$

- توجه کنید که برخلاف مساله بهینه سازی اولیه که بر مبنای تابع لاگرانژ بود، مساله دوگان کاملاً بر حسب داده های آموزش است.

- علاوه بر آن، تابع هزینه که باید بیشینه شود، فقط وابسته به ضرب داخلی الگوهای ورودی است

$$\{\mathbf{x}_i^T \mathbf{x}_j\}_{i,j=1}^N$$

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:  
بردارهای پشتیبان  $x^{(s)}$  زیرمجموعه ای از داده های آموزش هستند.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:  
بردارهای پشتیبان  $\mathbf{x}^{(s)}$  زیرمجموعه ای از داده های آموزش هستند.
- بنابراین، با در نظر گرفتن قید  $\alpha_i \geq 0$ ، فقط تعدادی از  $\alpha_i$  ها غیر صفراند و بقیه صفراند.  
یعنی این که بردار جواب، حالت پراکنده (sparse) دارد.

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:  
بردارهای پشتیبان  $\mathbf{x}^{(s)}$  زیرمجموعه ای از داده های آموزش هستند.
- بنابراین، با در نظر گرفتن قید  $\alpha_i \geq 0$ ، فقط تعدادی از  $\alpha_i$  ها غیر صفراند و بقیه صفراند.  
یعنی این که بردار جواب، حالت پراکنده (sparse) دارد.
- با حل مساله بهینه سازی مقید، ضرایب بهینه لاگرانژ  $(\alpha_{i,o})$  به دست می آید.



# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:  
بردارهای پشتیبان  $\mathbf{x}^{(s)}$  زیرمجموعه ای از داده‌های آموزش هستند.
- بنابراین، با در نظر گرفتن قید  $\alpha_i \geq 0$ ، فقط تعدادی از  $\alpha_i$  ها غیر صفراند و بقیه صفراند.  
یعنی این که بردار جواب، حالت پراکنده (sparse) دارد.
- با حل مساله بهینه‌سازی مقید، ضرایب بهینه لاگرانژ ( $\alpha_{i,o}$ ) به دست می‌آید.
- در نتیجه، بردار وزن‌ها برابر خواهد شد با

$$\mathbf{w}_o = \sum_{i=1}^{N_s} \alpha_{i,o} d_i \mathbf{x}_i$$

$N_s$  تعداد بردارهای پشتیبان (یعنی تعداد ضرایب غیر صفر لاگرانژ)

# ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- نکته مهم:  
بردارهای پشتیبان  $\mathbf{x}^{(s)}$  زیرمجموعه ای از داده های آموزش هستند.
- بنابراین، با در نظر گرفتن قید  $\alpha_i \geq 0$ ، فقط تعدادی از  $\alpha_i$  ها غیر صفراند و بقیه صفراند. یعنی این که بردار جواب، حالت پراکنده (sparse) دارد.
- با حل مساله بهینه سازی مقید، ضرایب بهینه لاگرانژ ( $\alpha_{i,o}$ ) به دست می آید.
- در نتیجه، بردار وزن ها برابر خواهد شد با

$$\mathbf{w}_o = \sum_{i=1}^{N_s} \alpha_{i,o} d_i \mathbf{x}_i$$

$N_s$  تعداد بردارهای پشتیبان (یعنی تعداد ضرایب غیر صفر لاگرانژ)

- برای محاسبه  $b_o$  ها:

$$\mathbf{w}_o^T \mathbf{x}^{(s)} + b_o = \pm 1 \quad \text{for} \quad d(s) = \pm 1$$

$$b_o = 1 - \sum_{i=1}^{N_s} \alpha_{i,o} d_i \mathbf{x}_i^T \mathbf{x}^{(s)}$$


# ماشین بردار پشتیبان (SVM)

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر


# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر



# ماشین بردار پشتیبان (SVM)


۲- ابرصفحه بهینه برای الگوهای جداناپذیر



- در این حالت، ابرصفحه نمی تواند الگوها را به طور کامل از یکدیگر جدا کند و بنابراین، خطای کلاسه بندی خواهیم داشت.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر




- در این حالت، ابرصفحه نمی تواند الگوها را به طور کامل از یکدیگر جدا کند و بنابراین، خطای کلاسه بندی خواهیم داشت.

- اگرچه مایلیم ابرصفحه ای بهینه ای به دست آوریم که خطای کلاسه بندی کمینه شود.

# ماشین بردار پشتیبان (SVM)

## ۲- ابرصفحه بهینه برای الگوهای جداناپذیر



- در این حالت، ابرصفحه نمی تواند الگوها را به طور کامل از یکدیگر جدا کند و بنابراین، خطای کلاسه بندی خواهیم داشت.

- اگرچه مایلیم ابرصفحه ای بهینه ای به دست آوریم که خطای کلاسه بندی کمینه شود.

- در این جا، چنانچه حاشیه جداسازی شرط

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, \dots, N$$

را نقض کند، در این صورت به آن «حاشیه جداسازی نرم» می گویند.



# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر


- این نقض کردن به دو صورت می تواند اتفاق بیافتد:

# ماشین بردار پشتیبان (SVM)

۲- ابر صفحه بهینه برای الگوهای جداناپذیر

– این نقض کردن به دو صورت می تواند اتفاق بیافتد:

۱- داده  $(\mathbf{x}_i, d_i)$  داخل ناحیه جداسازی قرار گرفته ولی در سمت صحیح سطح تصمیم گیری است.





# ماشین بردار پشتیبان (SVM)

۲- ابر صفحه بهینه برای الگوهای جداناپذیر

– این نقض کردن به دو صورت می تواند اتفاق بیافتد:

۱- داده  $(x_i, d_i)$  داخل ناحیه جداسازی قرار گرفته ولی در سمت صحیح سطح تصمیم گیری است.

۲- داده  $(x_i, d_i)$  در سمت غلط سطح تصمیم گیری قرار گرفته است.



# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$\xi_i$  متغیرهای شل (Slack Variables)

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$\xi_i$  متغیرهای شل (Slack Variables)

$0 < \xi_i \leq 1$  داده داخل ناحیه جداسازی ولی در سمت صحیح سطح تصمیم‌گیری قرار دارد

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$\xi_i$  متغیرهای شل (Slack Variables)

$0 < \xi_i \leq 1$  داده داخل ناحیه جداسازی ولی در سمت صحیح سطح تصمیم‌گیری قرار دارد

$\xi_i > 1$  داده در سمت غلط سطح تصمیم‌گیری قرار دارد



# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$\xi_i$  متغیرهای شل (Slack Variables)

$0 < \xi_i \leq 1$  داده داخل ناحیه جداسازی ولی در سمت صحیح سطح تصمیم‌گیری قرار دارد

$\xi_i > 1$  داده در سمت غلط سطح تصمیم‌گیری قرار دارد

- در این جا، بردارهای پشتیبان آن‌هایی هستند که نامعادله بالا را برای  $\xi_i > 0$  برآورده کنند.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای این حالت، متغیر غیرمنفی  $\{\xi_i\}_{i=1}^N$  را به صورت زیر به سطح تصمیم‌گیری اضافه می‌کنیم:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$\xi_i$  متغیرهای شل (Slack Variables)

$0 < \xi_i \leq 1$  داده داخل ناحیه جداسازی ولی در سمت صحیح سطح تصمیم‌گیری قرار دارد

$\xi_i > 1$  داده در سمت غلط سطح تصمیم‌گیری قرار دارد

- در این جا، بردارهای پشتیبان آن‌هایی هستند که نامعادله بالا را برای  $\xi_i > 0$  برآورده کنند.

- بنابراین، بردارهای پشتیبان دقیقا به همان شکل حالت جدناپذیر خطی تعریف و تعیین می‌شوند.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداپذیر

– هدف یافتن ابرصفحه جداکننده‌ای است که خطای کلاسه‌بندی را برای داده‌های آموزش کمینه کند:

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

– هدف یافتن ابرصفحه جداکننده‌ای است که خطای کلاسه‌بندی را برای داده‌های آموزش کمینه کند:

$$\phi(\xi) = \sum_{i=1}^N I(\xi_i - 1)$$

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- هدف یافتن ابرصفحه جداکننده‌ای است که خطای کلاسه‌بندی را برای داده‌های آموزش کمینه کند:

$$\phi(\xi) = \sum_{i=1}^N I(\xi_i - 1)$$

- این بهینه‌سازی با توجه به بردار وزن  $\mathbf{w}$ ، قید

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

و قید برروی  $\|\mathbf{w}\|^2$  انجام می‌شود و

$$I(\xi) = \begin{cases} 0 & \text{if } \xi \leq 0 \\ 1 & \text{if } \xi > 0 \end{cases}$$

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداپذیر

- هدف یافتن ابرصفحه جداکننده‌ای است که خطای کلاسه‌بندی را برای داده‌های آموزش کمینه کند:

$$\phi(\xi) = \sum_{i=1}^N I(\xi_i - 1)$$

- این بهینه‌سازی با توجه به بردار وزن  $\mathbf{w}$ ، قید

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

و قید برروی  $\|\mathbf{w}\|^2$  انجام می‌شود و

$$I(\xi) = \begin{cases} 0 & \text{if } \xi \leq 0 \\ 1 & \text{if } \xi > 0 \end{cases}$$

- متاسفانه این کمینه‌سازی با در نظر گرفتن  $\mathbf{w}$ ، مساله بهینه‌سازی نامحدب است.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

$$\phi(\xi) = \sum_{i=1}^N \xi_i$$



# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

$$\phi(\xi) = \sum_{i=1}^N \xi_i$$

علاوه بر آن، برای بهینه سازی  $\mathbf{w}$

$$\phi(\mathbf{w}, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

$C$  پارامتر متقابل تنظیم کننده  
(Reciprocal Regularization Parameter)

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

$$\phi(\xi) = \sum_{i=1}^N \xi_i$$

علاوه بر آن، برای بهینه سازی  $w$

$$\phi(w, \xi) = \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i$$

$C$  پارامتر متقابل تنظیم کننده

(Reciprocal Regularization Parameter)

•  $C$  بزرگ  $\equiv$  طراح SVM اعتماد زیادی به داده های آموزش دارد.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

$$\phi(\xi) = \sum_{i=1}^N \xi_i$$

علاوه بر آن، برای بهینه سازی  $\mathbf{w}$

$$\phi(\mathbf{w}, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

$C$  پارامتر متقابل تنظیم کننده

(Reciprocal Regularization Parameter)

- $C$  بزرگ  $\equiv$  طراح SVM اعتماد زیادی به داده های آموزش دارد.
- $C$  کوچک  $\equiv$  داده های آموزش نویزی است و اعتماد کمی باید به آن داشت.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- برای رفع این مشکل، تابع هزینه را به صورت زیر در نظر می گیریم:

$$\phi(\xi) = \sum_{i=1}^N \xi_i$$

علاوه بر آن، برای بهینه سازی  $\mathbf{w}$

$$\phi(\mathbf{w}, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

$C$  پارامتر متقابل تنظیم کننده

(Reciprocal Regularization Parameter)

- $C$  بزرگ  $\equiv$  طراح SVM اعتماد زیادی به داده های آموزش دارد.
- $C$  کوچک  $\equiv$  داده های آموزش نویزی است و اعتماد کمی باید به آن داشت.
- پارامتر  $C$  مصالحه ای بین پیچیدگی ماشین و تعداد نقاط جداناپذیر می کند.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله اولیه برای الگوهای جداناپذیر:

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

– مساله اولیه برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن مقدار بهینه  $w$  و  $b$  به طوری که قیود زیر را برآورده کرده:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$$\xi_i > 0 \quad \forall i$$

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله اولیه برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن مقدار بهینه  $w$  و  $b$  به طوری که قیود زیر را برآورده کرده:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$$\xi_i > 0 \quad \forall i$$

و به طوری که بردار  $w$  و متغیرهای شل تابع هزینه زیر را کمینه کنند:

$$J(\mathbf{w}, b, \alpha, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i]$$

که در آن  $C > 0$  توسط طراح تعیین می‌شود.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:



# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

که در آن  $C > 0$  توسط طراحی تعیین می‌شود.

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

که در آن  $C > 0$  توسط طراحی تعیین می‌شود.

- توجه کنید:

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

که در آن  $C > 0$  توسط طراحی تعیین می‌شود.

- توجه کنید:

۱- نه  $\xi_i$  ها در مساله دوگان ظاهر می‌شوند و نه ضرایب لاگرانژ آن‌ها

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

که در آن  $C > 0$  توسط طراحی تعیین می‌شود.

- توجه کنید:

۱- نه  $\xi_i$  ها در مساله دوگان ظاهر می‌شوند و نه ضرایب لاگرانژ آن‌ها

۲- مساله دوگان برای الگوهای جداناپذیر همانند حالت جداپذیر است به غیر از  $0 \leq \alpha_i \leq C$

# ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- مساله دوگان برای الگوهای جداناپذیر:

با توجه به داده‌های موجود  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ  $\{\alpha_i\}_{i=1}^N$  که تابع هزینه زیر را بیشینه کند:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

که در آن  $C > 0$  توسط طراحی تعیین می‌شود.

- توجه کنید:

۱- نه  $\xi_i$  ها در مساله دوگان ظاهر می‌شوند و نه ضرایب لاگرانژ آن‌ها

۲- مساله دوگان برای الگوهای جداناپذیر همانند حالت جداپذیر است به غیر از  $0 \leq \alpha_i \leq C$

۳- بردارهای پشتیبان همانند حالت قبل تعیین می‌شوند.

# ماشین بردار پشتیبان (SVM)

– فلسفه SVM برای کلاسه‌بندی الگوها

# ماشین بردار پشتیبان (SVM)

– فلسفه SVM برای کلاسه‌بندی الگوها

– اصول SVM




# ماشین بردار پشتیبان (SVM)

- فلسفه SVM برای کلاسه‌بندی الگوها

- اصول SVM

۱- نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها




# ماشین بردار پشتیبان (SVM)

- فلسفه SVM برای کلاسه‌بندی الگوها

- اصول SVM

۱- نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها

۲- تشکیل ابرصفحه بهینه برای جداسازی ویژگی‌ها که در قسمت ۱ کشف شدند.




# ماشین بردار پشتیبان (SVM)

– فلسفه SVM برای کلاسه‌بندی الگوها

– اصول SVM

۱– نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها

۲– تشکیل ابرصفحه بهینه برای جداسازی ویژگی‌ها که در قسمت ۱ کشف شدند.



نکته مهم: نظریه SVM، به طور تحلیلی ابعاد بهینه برای فضای پنهان پیدامی‌کند.