



شبکه‌های عصبی مصنوعی


جلسه پانزدهم:

ماشین بردار پشتیبان (۳)

(Support Vector Machine = SVM)

ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی


- حل مساله اولیه و یافتن وزن های بهینه:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- حل مساله اولیه و یافتن وزن های بهینه:


$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

ایجاد نقطه زینی (Saddle Point)



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- حل مساله اولیه و یافتن وزن های بهینه:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$


ایجاد نقطه زینی (Saddle Point)

- حل مساله دوگان و یافتن ضرایب لاگرانژ:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$\alpha_i \geq 0 \quad i = 1, \dots, N$$



ماشین بردار پشتیبان (SVM)

۱- ابرصفحه بهینه برای الگوهای جداپذیر خطی

- حل مساله اولیه و یافتن وزن های بهینه:

$$\phi(\mathbf{w}) = \min \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0 \quad \text{for } i = 1, \dots, N$$

- تابع لاگرانژ

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

ایجاد نقطه زینی (Saddle Point)


- حل مساله دوگان و یافتن ضرایب لاگرانژ:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$\alpha_i \geq 0 \quad i = 1, \dots, N$$


تعیین بردارهای پشتیبان $\mathbf{x}^{(s)}$



ماشین بردار پشتیبان (SVM)

ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر



ماشین بردار پشتیبان (SVM)


۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- حل مساله اولیه و یافتن وزن های بهینه:

$$J(\mathbf{w}, b, \alpha, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i]$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$$\xi_i > 0 \quad \forall i$$



ماشین بردار پشتیبان (SVM)

۲- ابرصفحه بهینه برای الگوهای جداناپذیر

- حل مساله اولیه و یافتن وزن های بهینه:

$$J(\mathbf{w}, b, \alpha, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [d_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i]$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad i = 1, \dots, N$$

$$\xi_i > 0 \quad \forall i$$


- حل مساله دوگان و یافتن ضرایب لاگرانژ:

$$\phi(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C$$

تعیین بردارهای پشتیبان $\mathbf{x}^{(s)}$



ماشین بردار پشتیبان (SVM)

– فلسفه SVM برای کلاسه‌بندی الگوها

ماشین بردار پشتیبان (SVM)

– فلسفه SVM برای کلاسه‌بندی الگوها


– اصول SVM

ماشین بردار پشتیبان (SVM)

- فلسفه SVM برای کلاسه‌بندی الگوها

- اصول SVM

۱- نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها




ماشین بردار پشتیبان (SVM)

- فلسفه SVM برای کلاسه‌بندی الگوها

- اصول SVM

۱- نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها

۲- تشکیل ابرصفحه بهینه برای جداسازی ویژگی‌ها که در قسمت ۱ کشف شدند.




ماشین بردار پشتیبان (SVM)

- فلسفه SVM برای کلاسه‌بندی الگوها

- اصول SVM

۱- نگاشت غیرخطی بردار ورودی به فضای ویژگی‌ها

۲- تشکیل ابرصفحه بهینه برای جداسازی ویژگی‌ها که در قسمت ۱ کشف شدند.



نکته مهم: نظریه SVM، به طور تحلیلی ابعاد بهینه برای فضای پنهان پیدامی‌کند.

ماشین بردار پشتیبان (SVM)

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- فرض کنید:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– فرض کنید:

• بردار x از فضای ورودی با بُعد m_0 انتخاب شده است

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– فرض کنید:

- بردار \mathbf{x} از فضای ورودی با بُعد m_0 انتخاب شده است
- مجموعه‌ای از توابع غیرخطی که فضای ورودی را به فضای ویژگی‌ها انتقال می‌دهد. $\{\varphi_j(\mathbf{x})\}_{j=1}^{\infty}$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- فرض کنید:

- بردار \mathbf{x} از فضای ورودی با بُعد m_0 انتخاب شده است
- مجموعه‌ای از توابع غیرخطی که فضای ورودی را به فضای ویژگی‌ها انتقال می‌دهد. $\{\varphi_j(\mathbf{x})\}_{j=1}^{\infty}$

- ابرصفحه به عنوان سطح تصمیم‌گیری

$$\sum_{j=1}^{\infty} w_j \varphi_j(\mathbf{x}) = 0$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- فرض کنید:

- بردار \mathbf{x} از فضای ورودی با بُعد m_0 انتخاب شده است
- مجموعه‌ای از توابع غیرخطی که فضای ورودی را به فضای ویژگی‌ها انتقال می‌دهد. $\{\varphi_j(\mathbf{x})\}_{j=1}^{\infty}$

- ابرصفحه به عنوان سطح تصمیم‌گیری

$$\sum_{j=1}^{\infty} w_j \varphi_j(\mathbf{x}) = 0$$

مجموعه‌ای بی‌نهایت بزرگ از وزن‌ها که فضای ویژگی‌ها را به فضای خروجی انتقال می‌دهد. $\{w_j\}_{j=1}^{\infty}$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- فرض کنید:

- بردار \mathbf{x} از فضای ورودی با بُعد m_0 انتخاب شده است
- مجموعه‌ای از توابع غیرخطی که فضای ورودی را به فضای ویژگی‌ها انتقال می‌دهد. $\{\varphi_j(\mathbf{x})\}_{j=1}^{\infty}$

- ابرصفحه به عنوان سطح تصمیم‌گیری

$$\sum_{j=1}^{\infty} w_j \varphi_j(\mathbf{x}) = 0$$

مجموعه‌ای بی‌نهایت بزرگ از وزن‌ها که فضای ویژگی‌ها را به فضای خروجی انتقال می‌دهد. $\{w_j\}_{j=1}^{\infty}$

- به فرم برداری

$$\mathbf{w}^T \Phi(\mathbf{x}) = 0$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- فرض کنید:

- بردار \mathbf{x} از فضای ورودی با بُعد m_0 انتخاب شده است
- مجموعه‌ای از توابع غیرخطی که فضای ورودی را به فضای ویژگی‌ها انتقال می‌دهد. $\{\varphi_j(\mathbf{x})\}_{j=1}^{\infty}$

- ابرصفحه به عنوان سطح تصمیم‌گیری

$$\sum_{j=1}^{\infty} w_j \varphi_j(\mathbf{x}) = 0$$

مجموعه‌ای بی‌نهایت بزرگ از وزن‌ها که فضای ویژگی‌ها را به فضای خروجی انتقال می‌دهد. $\{w_j\}_{j=1}^{\infty}$

- به فرم برداری

$$\mathbf{w}^T \Phi(\mathbf{x}) = 0$$

$\Phi(\mathbf{x})$ بردار ویژگی‌ها

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– همانند قبل، به دنبال «جداپذیری خطی» الگوهای انتقال یافته به فضای ویژگی‌ها هستیم.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– همانند قبل، به دنبال «جداپذیری خطی» الگوهای انتقال یافته به فضای ویژگی‌ها هستیم.

– با توجه به این هدف، معادله وزن‌ها را که قبلاً به صورت $\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \mathbf{x}_i$ بود، را به فرم زیر ارایه می‌کنیم:

$$\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \Phi(\mathbf{x}_i)$$

$$\Phi(\mathbf{x}_i) = [\varphi_1(\mathbf{x}_i), \varphi_2(\mathbf{x}_i), \dots]^T$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- همانند قبل، به دنبال «جداپذیری خطی» الگوهای انتقال یافته به فضای ویژگی‌ها هستیم.

- با توجه به این هدف، معادله وزن‌ها را که قبلاً به صورت $\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \mathbf{x}_i$ بود، را به فرم زیر ارایه می‌کنیم:

$$\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \Phi(\mathbf{x}_i)$$

$$\Phi(\mathbf{x}_i) = [\varphi_1(\mathbf{x}_i), \varphi_2(\mathbf{x}_i), \dots]^T$$

- با قراردادن این رابطه در $\mathbf{w}^T \Phi(\mathbf{x}) = 0$ خواهیم داشت:

$$\sum_{i=1}^{Ns} \alpha_i d_i \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x}) = 0$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- همانند قبل، به دنبال «جداپذیری خطی» الگوهای انتقال یافته به فضای ویژگی‌ها هستیم.

- با توجه به این هدف، معادله وزن‌ها را که قبلاً به صورت $\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \mathbf{x}_i$ بود، را به فرم زیر ارایه می‌کنیم:

$$\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \Phi(\mathbf{x}_i)$$

$$\Phi(\mathbf{x}_i) = [\varphi_1(\mathbf{x}_i), \varphi_2(\mathbf{x}_i), \dots]^T$$

- با قراردادن این رابطه در $\mathbf{w}^T \Phi(\mathbf{x}) = 0$ خواهیم داشت:

$$\sum_{i=1}^{Ns} \alpha_i d_i \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x}) = 0$$

- ضرب داخلی را با اسکالر زیر نشان می‌دهیم:

$$k(\mathbf{x}, \mathbf{x}_i) = \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x})$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- همانند قبل، به دنبال «جدآوری خطی» الگوهای انتقال یافته به فضای ویژگی‌ها هستیم.

- با توجه به این هدف، معادله وزن‌ها را که قبلاً به صورت $\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \mathbf{x}_i$ بود، را به فرم زیر ارایه می‌کنیم:

$$\mathbf{w} = \sum_{i=1}^{Ns} \alpha_i d_i \Phi(\mathbf{x}_i)$$

$$\Phi(\mathbf{x}_i) = [\varphi_1(\mathbf{x}_i), \varphi_2(\mathbf{x}_i), \dots]^T$$

- با قراردادن این رابطه در $\mathbf{w}^T \Phi(\mathbf{x}) = 0$ خواهیم داشت:

$$\sum_{i=1}^{Ns} \alpha_i d_i \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x}) = 0$$

- ضرب داخلی را با اسکالر زیر نشان می‌دهیم:

$$\begin{aligned} k(\mathbf{x}, \mathbf{x}_i) &= \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x}) \\ &= \sum_{j=1}^{\infty} \varphi_j(\mathbf{x}_i) \varphi_j(\mathbf{x}) \quad i = 1, \dots, Ns \end{aligned}$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرصفحه) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرصفحه) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

$k(\mathbf{x}, \mathbf{x}_i)$ ضرب داخلی کرنل (یا به طور ساده، کرنل) که به صورت زیر تعریف می‌شود:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرصفحه) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

$k(\mathbf{x}, \mathbf{x}_i)$ ضرب داخلی کرنل (یا به طور ساده، کرنل) که به صورت زیر تعریف می‌شود:

کرنل $k(\mathbf{x}, \mathbf{x}_i)$ تابعی است که ضرب داخلی تصاویر تشکیل شده در فضای ویژگی‌ها را برای دو نقطه در فضای ورودی با استفاده از Φ محاسبه می‌کند.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرصفحه) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

$k(\mathbf{x}, \mathbf{x}_i)$ ضرب داخلی کرنل (یا به طور ساده، کرنل) که به صورت زیر تعریف می‌شود:

کرنل $k(\mathbf{x}, \mathbf{x}_i)$ تابعی است که ضرب داخلی تصاویر تشکیل شده در فضای ویژگی‌ها را برای دو نقطه در فضای ورودی با استفاده از Φ محاسبه می‌کند.

- دوخاصیت کرنل:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرصفحه) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

$k(\mathbf{x}, \mathbf{x}_i)$ ضرب داخلی کرنل (یا به طور ساده، کرنل) که به صورت زیر تعریف می‌شود:

کرنل $k(\mathbf{x}, \mathbf{x}_i)$ تابعی است که ضرب داخلی تصاویر تشکیل شده در فضای ویژگی‌ها را برای دو نقطه در فضای ورودی با استفاده از Φ محاسبه می‌کند.

- دوخاصیت کرنل:

۱- تابع $k(\mathbf{x}, \mathbf{x}_i)$ حول نقطه مرکز (\mathbf{x}_i) متقارن است

$$k(\mathbf{x}, \mathbf{x}_i) = k(\mathbf{x}_i, \mathbf{x}) \quad \forall \mathbf{x}_i$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

- بنابراین، سطح تصمیم‌گیری بهینه (ابرفضا) در فضای خروجی برابر است با

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

$k(\mathbf{x}, \mathbf{x}_i)$ ضرب داخلی کرنل (یا به طور ساده، کرنل) که به صورت زیر تعریف می‌شود:

کرنل $k(\mathbf{x}, \mathbf{x}_i)$ تابعی است که ضرب داخلی تصاویر تشکیل شده در فضای ویژگی‌ها را برای دو نقطه در فضای ورودی با استفاده از Φ محاسبه می‌کند.

- دوخاصیت کرنل:

۱- تابع $k(\mathbf{x}, \mathbf{x}_i)$ حول نقطه مرکز (\mathbf{x}_i) متقارن است

$$k(\mathbf{x}, \mathbf{x}_i) = k(\mathbf{x}_i, \mathbf{x}) \quad \forall \mathbf{x}_i$$

۲- سطح (حجم) زیر منحنی تابع $k(\mathbf{x}, \mathbf{x}_i)$ مقداری ثابت است.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

- ۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم. به عبارت دیگر، هیچگاه نیاز به محاسبه صریح بردار وزن \mathbf{w}_o نداریم.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم.

به عبارت دیگر، هیچگاه نیاز به محاسبه صریح بردار وزن \mathbf{w}_o نداریم.

به همین جهت، استفاده از $k(\mathbf{x}, \mathbf{x}_i) = \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x})$ را شعبده‌بازی کرنل می‌نامند.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم.

به عبارت دیگر، هیچگاه نیاز به محاسبه صریح بردار وزن \mathbf{w}_o نداریم.

به همین جهت، استفاده از $k(\mathbf{x}, \mathbf{x}_i) = \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x})$ را شعبده‌بازی کرنل می‌نامند.

۲- اگرچه فرض کردیم که فضای ویژگی‌ها می‌تواند دارای ابعاد بی‌نهایت باشد،

معادله خطی ابر صفحه بالا از تعداد محدودی جمله تشکیل می‌شود.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم.

به عبارت دیگر، هیچگاه نیاز به محاسبه صریح بردار وزن \mathbf{w}_o نداریم.

به همین جهت، استفاده از $k(\mathbf{x}, \mathbf{x}_i) = \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x})$ را شعبده‌بازی کرنل می‌نامند.

۲- اگرچه فرض کردیم که فضای ویژگی‌ها می‌تواند دارای ابعاد بی‌نهایت باشد،

معادله خطی ابر صفحه بالا از تعداد محدودی جمله تشکیل می‌شود.

– به خاطر نکته ۱، به ماشین بردار پشتیبان، ماشین کرنل نیز می‌گویند.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

شعبده بازی کرنل:

– معادله سطح تصمیم‌گیری را مجدداً در نظر بگیرید:

$$\sum_{i=1}^{N_s} \alpha_i d_i k(\mathbf{x}, \mathbf{x}_i) = 0$$

– در مورد این معادله، دو نکته قابل تأمل است:

۱- برای کلاسه‌بندی الگوها در فضای خروجی، فقط نیاز به کرنل $k(\mathbf{x}, \mathbf{x}_i)$ داریم.

به عبارت دیگر، هیچگاه نیاز به محاسبه صریح بردار وزن \mathbf{w}_0 نداریم.

به همین جهت، استفاده از $k(\mathbf{x}, \mathbf{x}_i) = \Phi^T(\mathbf{x}_i) \Phi(\mathbf{x})$ را شعبده‌بازی کرنل می‌نامند.

۲- اگرچه فرض کردیم که فضای ویژگی‌ها می‌تواند دارای ابعاد بی‌نهایت باشد،

معادله خطی ابر صفحه بالا از تعداد محدودی جمله تشکیل می‌شود.

– به خاطر نکته ۱، به ماشین بردار پشتیبان، ماشین کرنل نیز می‌گویند.

– برای مقاصد کلاسه‌بندی الگو، پارامترهای ماشین توسط یک بردار N -بُعدی تعیین می‌شود که

برای جمله i آن برابر است با $\alpha_i d_i \quad i = 1, \dots, N$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس مقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

قضیه مرسر (Mercer's Theorem):

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

قضیه مرسر (Mercer's Theorem):

– فرض کنید $k(\mathbf{x}, \mathbf{x}')$ کرنل متقارن و پیوسته ای باشد که در بازه $a \leq \mathbf{x}, \mathbf{x}' \leq b$ تعریف شده باشد. بسط کرنل $k(\mathbf{x}, \mathbf{x}')$ را می توان با استفاده از ثابت $\lambda_i > 0$ به صورت زیر ارایه کرد:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

قضیه مرسر (Mercer's Theorem):

– فرض کنید $k(\mathbf{x}, \mathbf{x}')$ کرنل متقارن و پیوسته ای باشد که در بازه $a \leq \mathbf{x}, \mathbf{x}' \leq b$ تعریف شده باشد. بسط کرنل $k(\mathbf{x}, \mathbf{x}')$ را می توان با استفاده از ثابت $\lambda_i > 0$ به صورت زیر ارایه کرد:

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

قضیه مرسر (Mercer's Theorem):

– فرض کنید $k(\mathbf{x}, \mathbf{x}')$ کرنل متقارن و پیوسته ای باشد که در بازه $a \leq \mathbf{x}, \mathbf{x}' \leq b$ تعریف شده باشد. بسط کرنل $k(\mathbf{x}, \mathbf{x}')$ را می توان با استفاده از ثابت $\lambda_i > 0$ به صورت زیر ارایه کرد:

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

برای این که این بسط معتبر باشد و همچنین همگرای مطلق و پیوسته باشد، شرط لازم و کافی زیر باید برقرار باشد:

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

– می توان $\{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$ را به عنوان درایه ij ام ماتریس متقارن زیر در نظر گرفت:

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماتریس \mathbf{K} ماتریسی غیرمنفی است به نام ماتریس کرنل که گرام (Gram) نیز می نامند.

قضیه مرسر (Mercer's Theorem):

– فرض کنید $k(\mathbf{x}, \mathbf{x}')$ کرنل متقارن و پیوسته ای باشد که در بازه $a \leq \mathbf{x}, \mathbf{x}' \leq b$ تعریف شده باشد. بسط کرنل $k(\mathbf{x}, \mathbf{x}')$ را می توان با استفاده از ثابت $\lambda_i > 0$ به صورت زیر ارایه کرد:

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

برای این که این بسط معتبر باشد و همچنین همگرای مطلق و پیوسته باشد، شرط لازم و کافی زیر باید برقرار باشد:

$$\int_a^b \int_a^b k(\mathbf{x}, \mathbf{x}') \psi(\mathbf{x}) \psi(\mathbf{x}') d\mathbf{x} d\mathbf{x}' = 0$$

$$\int_a^b \psi^2(\mathbf{x}) d\mathbf{x} < \infty$$

به طوری که

ماشین بردار پشتیبان (SVM)

۳-SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$: توابع ویژه (Eigenfunctions)

ماشین بردار پشتیبان (SVM)

۳-SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$ توابع ویژه (Eigenfunctions)

λ_i مقادیر ویژه (Eigenvalues)

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$ توابع ویژه (Eigenfunctions)

λ_i مقادیر ویژه (Eigenvalues)

– توجه: قضیه مرسر فقط می‌گوید که تابع انتخاب شده، کرنل ضرب داخلی است یا خیر.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$ توابع ویژه (Eigenfunctions)

λ_i مقادیر ویژه (Eigenvalues)

– توجه: قضیه مرسر فقط می‌گوید که تابع انتخاب شده، کرنل ضرب داخلی است یا خیر. این قضیه چیزی در مورد چگونگی تشکیل این تابع نمی‌گوید.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$ توابع ویژه (Eigenfunctions)

λ_i مقادیر ویژه (Eigenvalues)

- توجه: قضیه مرسر فقط می‌گوید که تابع انتخاب شده، کرنل ضرب داخلی است یا خیر. این قضیه چیزی در مورد چگونگی تشکیل این تابع نمی‌گوید.
- قضیه مرسر از آن جهت مهم است که تعداد کرنل‌ها را محدود می‌کند.

ماشین بردار پشتیبان (SVM)

۳- SVM با استفاده از توابع کرنل

$$k(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}')$$

$\varphi_i(\mathbf{x})$ توابع ویژه (Eigenfunctions)

λ_i مقادیر ویژه (Eigenvalues)

- توجه: قضیه مرسر فقط می گوید که تابع انتخاب شده، کرنل ضرب داخلی است یا خیر. این قضیه چیزی در مورد چگونگی تشکیل این تابع نمی گوید.

- قضیه مرسر از آن جهت مهم است که تعداد کرنل ها را محدود می کند.

نتیجه گیری: بسط

$$k(\mathbf{x}, \mathbf{x}_i) = \sum_{j=1}^{\infty} \varphi_j(\mathbf{x}_i) \varphi_j(\mathbf{x})$$

حالت خاصی از قضیه مرسر است با $\lambda_i = 1$

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

– ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می‌دهد که سطح تصمیم‌گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی‌ها، خطی است.

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

- ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می دهد که سطح تصمیم گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی ها، خطی است.
- برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه سازی مقید داریم.

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

- ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می دهد که سطح تصمیم گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی ها، خطی است.
- برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه سازی مقید داریم.
- با توجه به داده های آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ $\{\alpha_i\}_{i=1}^N$ که تابع هزینه زیر را بیشینه کند:

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

– ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می‌دهد که سطح تصمیم‌گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی‌ها، خطی است.

– برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه‌سازی مقید داریم. با توجه به داده‌های آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ $\{\alpha_i\}_{i=1}^N$ که تابع هزینه زیر را بیشینه کند:

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

– ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می‌دهد که سطح تصمیم‌گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی‌ها، خطی است.

– برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه سازی مقید داریم. با توجه به داده‌های آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ $\{\alpha_i\}_{i=1}^N$ که تابع هزینه زیر را بیشینه کند:

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

– ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می‌دهد که سطح تصمیم‌گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی‌ها، خطی است.

– برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه‌سازی مقید داریم. با توجه به داده‌های آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ $\{\alpha_i\}_{i=1}^N$ که تابع هزینه زیر را بیشینه کند:

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

که در آن $C > 0$ توسط طراح تعیین می‌شود.

ماشین بردار پشتیبان (SVM)

طراحی ماشین بردار پشتیبان:

– ابتدا توجه کنید که کرنل $k(\mathbf{x}, \mathbf{x}_i)$ به ما اجازه می‌دهد که سطح تصمیم‌گیری غیرخطی را در فضای ورودی تشکیل دهیم به طوری که شکل این سطح در فضای ویژگی‌ها، خطی است.

– برای طراحی ماشین بردار پشتیبان فقط نیاز به استفاده از فرم دوگان بهینه‌سازی مقید داریم. با توجه به داده‌های آموزش $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ ، مطلوب است یافتن ضرایب لاگرانژ $\{\alpha_i\}_{i=1}^N$ که تابع هزینه زیر را بیشینه کند:

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

با در نظر گرفتن قیود

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

که در آن $C > 0$ توسط طراح تعیین می‌شود.

– توجه کنید که این مساله دوگان دقیقاً مثل حالت «الگوهای جداناپذیر» است با این تفاوت که به جای ضرب داخلی $\mathbf{x}_i^T \mathbf{x}_j$ از کرنل $k(\mathbf{x}, \mathbf{x}_i)$ استفاده شده است.

ماشین بردار پشتیبان (SVM)

– مثال‌هایی از ماشین بردار پشتیبان:

ماشین بردار پشتیبان (SVM)

– مثال‌هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

ماشین بردار پشتیبان (SVM)

– مثال هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

۱- کرنل های مرسر چندجمله ای و RBF همواره قضیه مرسر را برآورده می کند.

ماشین بردار پشتیبان (SVM)

– مثال هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

۱- کرنل های مرسر چندجمله ای و RBF همواره قضیه مرسر را برآورده می کند.

۲- کرنل مرسر tanh به این واقعیت اشاره دارد که تعیین کرنل مرسر همواره کار ساده ای نیست.

ماشین بردار پشتیبان (SVM)

– مثال هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

۱- کرنل های مرسر چند جمله ای و RBF همواره قضیه مرسر را برآورده می کند.

۲- کرنل مرسر \tanh به این واقعیت اشاره دارد که تعیین کرنل مرسر همواره کار ساده ای نیست.

۳- برای هر سه نوع ماشین، ابعاد فضای ویژگی ها (تعداد سلول ها) توسط تعداد بردارهای پشتیبان که از حل مساله بهینه سازی مقید به دست می آید، تعیین می شود.

ماشین بردار پشتیبان (SVM)

– مثال هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

۱- کرنل های مرسر چند جمله ای و RBF همواره قضیه مرسر را برآورده می کند.

۲- کرنل مرسر \tanh به این واقعیت اشاره دارد که تعیین کرنل مرسر همواره کار ساده ای نیست.

۳- برای هر سه نوع ماشین، ابعاد فضای ویژگی ها (تعداد سلول ها) توسط تعداد بردارهای پشتیبان که از حل مساله بهینه سازی مقید به دست می آید، تعیین می شود.

۴- در ماشین بردار پشتیبان، برخلاف RBF و MLP، نیازی به استفاده از روش های ابتکاری نیست.

ماشین بردار پشتیبان (SVM)

– مثال هایی از ماشین بردار پشتیبان:

Type of support vector machine	Mercer kernel $k(\mathbf{x}, \mathbf{x}_i), i = 1, 2, \dots, N$	Comments
Polynomial learning machine	$(\mathbf{x}^T \mathbf{x}_i + 1)^p$	Power p is specified <i>a priori</i> by the user
Radial-basis-function network	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	The width σ^2 , common to all the kernels, is specified <i>a priori</i> by the user
Two-layer perceptron	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	Mercer's theorem is satisfied only for some values of β_0 and β_1

۱- کرنل های مرسر چند جمله ای و RBF همواره قضیه مرسر را برآورده می کند.

۲- کرنل مرسر \tanh به این واقعیت اشاره دارد که تعیین کرنل مرسر همواره کار ساده ای نیست.

۳- برای هر سه نوع ماشین، ابعاد فضای ویژگی ها (تعداد سلول ها) توسط تعداد بردارهای پشتیبان که از حل مساله بهینه سازی مقید به دست می آید، تعیین می شود.

۴- در ماشین بردار پشتیبان، برخلاف RBF و MLP، نیازی به استفاده از روش های ابتکاری نیست.

۵- در ماشین بردار پشتیبان RBF، تعداد RBF ها و مرکز آن ها به ترتیب توسط بردارهای پشتیبان و مقدار آن ها تعیین می شود.

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

بنابراین

$$k(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

بنابراین

$$k(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

در نتیجه می توان استنباط کرد که تصویر انتقال یافته \mathbf{x} به فضای ویژگی ها برابر است با

$$\phi(\mathbf{x}) = [1, x_1^2, \sqrt{2}x_1 x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	+1
$(+1, -1)$	+1
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

بنابراین

$$k(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

در نتیجه می توان استنباط کرد که تصویر انتقال یافته \mathbf{x} به فضای ویژگی ها برابر است با

$$\phi(\mathbf{x}) = [1, x_1^2, \sqrt{2}x_1 x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$$

و به همین ترتیب برای \mathbf{x}_i

$$\phi(\mathbf{x}_i) = [1, x_{i1}^2, \sqrt{2}x_{i1} x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}]^T, \quad i = 1, 2, 3, 4$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

بنابراین

$$k(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

در نتیجه می توان استنباط کرد که تصویر انتقال یافته \mathbf{x} به فضای ویژگی ها برابر است با

$$\phi(\mathbf{x}) = [1, x_1^2, \sqrt{2}x_1 x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$$

و به همین ترتیب برای \mathbf{x}_i

$$\phi(\mathbf{x}_i) = [1, x_{i1}^2, \sqrt{2}x_{i1} x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}]^T, \quad i = 1, 2, 3, 4$$

ماتریس کرنل (گرام)

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

x_1, x_2	d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1

- کرنل در نظر گرفته شده $k(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x}^T \mathbf{x}_i)^2$

$$\mathbf{x} = [x_1 \ x_2]^T \quad \mathbf{x}_i = [x_{i1} \ x_{i2}]^T$$

بنابراین

$$k(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

در نتیجه می توان استنباط کرد که تصویر انتقال یافته \mathbf{x} به فضای ویژگی ها برابر است با

$$\phi(\mathbf{x}) = [1, x_1^2, \sqrt{2}x_1 x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$$

و به همین ترتیب برای \mathbf{x}_i

$$\phi(\mathbf{x}_i) = [1, x_{i1}^2, \sqrt{2}x_{i1} x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}]^T, \quad i = 1, 2, 3, 4$$

ماتریس کرنل (گرام)

$$\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N \rightarrow \mathbf{K} = \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 9 & 1 & 1 \\ 1 & 1 & 9 & 1 \\ 1 & 1 & 1 & 9 \end{bmatrix}$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

تابع هزینه مساله دوگان بهینه سازی

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

تابع هزینه مساله دوگان بهینه سازی

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

$$Q(\alpha) = \alpha_1 + \alpha_2 + \alpha_3 + \alpha_4 - \frac{1}{2} (9\alpha_1^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3 + 2\alpha_1\alpha_4 \\ + 9\alpha_2^2 + 2\alpha_2\alpha_3 - 2\alpha_2\alpha_4 + 9\alpha_3^2 - 2\alpha_3\alpha_4 + 9\alpha_4^2)$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

تابع هزینه مساله دوگان بهینه‌سازی

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j)$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, \dots, N$$

$$Q(\alpha) = \alpha_1 + \alpha_2 + \alpha_3 + \alpha_4 - \frac{1}{2} (9\alpha_1^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3 + 2\alpha_1\alpha_4 \\ + 9\alpha_2^2 + 2\alpha_2\alpha_3 - 2\alpha_2\alpha_4 + 9\alpha_3^2 - 2\alpha_3\alpha_4 + 9\alpha_4^2)$$

بهینه‌سازی این تابع هزینه بر حسب ضرایب لاگرانژ، نتیجه می‌دهد:

$$9\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 = 1$$

$$-\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1$$

$$-\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1$$

$$\alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

بهینه‌سازی این تابع هزینه بر حسب ضرایب لاگرانژ، نتیجه می‌دهد:

$$9\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 = 1$$

$$-\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1$$

$$-\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1$$

$$\alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

بهینه‌سازی این تابع هزینه بر حسب ضرایب لاگرانژ، نتیجه می‌دهد:

$$9\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 = 1$$

$$-\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1$$

$$-\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1$$

$$\alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1$$

بنابراین، مقدار بهینه این ضرایب برابراند با

$$\alpha_{o,1} = \alpha_{o,2} = \alpha_{o,3} = \alpha_{o,4} = \frac{1}{8}$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

بهینه‌سازی این تابع هزینه بر حسب ضرایب لاگرانژ، نتیجه می‌دهد:

$$9\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 = 1$$

$$-\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1$$

$$-\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1$$

$$\alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1$$

بنابراین، مقدار بهینه این ضرایب برابراند با

$$\alpha_{o,1} = \alpha_{o,2} = \alpha_{o,3} = \alpha_{o,4} = \frac{1}{8}$$

یعنی این که هر چهار بردار ورودی، بردار پشتیبان هستند. یعنی رابطه

$$\sum_{i=1}^N \alpha_i d_i = 0$$

برای تمامی داده‌ها، برقرار است.

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که

$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$

ماشین بردار پشتیبان (SVM)


مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که

$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$



ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه


$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که

$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$

با استفاده از

$$\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \Phi(\mathbf{x}_i)$$



ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که


$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$

با استفاده از

$$\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \Phi(\mathbf{x}_i)$$

خواهیم داشت

$$\mathbf{w}_o = \frac{1}{8} [-\varphi(\mathbf{x}_1) + \varphi(\mathbf{x}_2) + \varphi(\mathbf{x}_3) - \varphi(\mathbf{x}_4)]$$



ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که

$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$


با استفاده از

$$\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \Phi(\mathbf{x}_i)$$

خواهیم داشت

$$\mathbf{w}_o = \frac{1}{8} [-\varphi(\mathbf{x}_1) + \varphi(\mathbf{x}_2) + \varphi(\mathbf{x}_3) - \varphi(\mathbf{x}_4)]$$

$$= \frac{1}{8} \left[- \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \end{bmatrix} \right]$$



ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

مقدار بهینه تابع هزینه

$$Q_o(\alpha) = \frac{1}{4}$$

از آن جا می توان نتیجه گرفت که

$$\frac{1}{2} \|\mathbf{w}_o\|^2 = \frac{1}{4} \Rightarrow \|\mathbf{w}_o\| = \frac{1}{\sqrt{2}}$$


با استفاده از

$$\mathbf{w} = \sum_{i=1}^{N_s} \alpha_i d_i \Phi(\mathbf{x}_i)$$

خواهیم داشت

$$\mathbf{w}_o = \frac{1}{8} [-\varphi(\mathbf{x}_1) + \varphi(\mathbf{x}_2) + \varphi(\mathbf{x}_3) - \varphi(\mathbf{x}_4)]$$

$$= \frac{1}{8} \left[- \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \end{bmatrix} \right] = \begin{bmatrix} 0 \\ 0 \\ -1/\sqrt{2} \\ 0 \\ 0 \\ 0 \end{bmatrix}$$



ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ابر صفحه بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ابر صفحه بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0 \Rightarrow \left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ابر صفحه بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0 \Rightarrow \left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0 \Rightarrow -x_1x_2 = 0$$

ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ابر صفحه بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0 \Rightarrow \left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0 \Rightarrow -x_1x_2 = 0$$

x_1, x_2	y
$(-1, -1)$	-1
$(-1, +1)$	+1
$(+1, -1)$	+1
$(+1, +1)$	-1


ماشین بردار پشتیبان (SVM)

مثال: مساله XOR

ابر صفحه بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0 \Rightarrow \left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0 \Rightarrow -x_1x_2 = 0$$

x_1, x_2	y
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1




ماشین چند جمله‌ای

ماشین بردار پشتیبان (SVM)


مثال: مساله XOR

ابرفضا بهینه

$$\mathbf{w}_o^T \phi(\mathbf{x}) = 0 \Rightarrow \left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0 \Rightarrow -x_1x_2 = 0$$



ماشین چندجمله‌ای



تصویر القاشده به فضای ویژگی‌ها

x_1, x_2	y
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1


ماشین بردار پشتیبان (SVM)

مثال: کلاسه بندی کلاس های ماه شکل

ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل


Classification using SVM with distance = -6, radius = 10, and width = 6



ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل

Classification using SVM with distance = -6, radius = 10, and width = 6



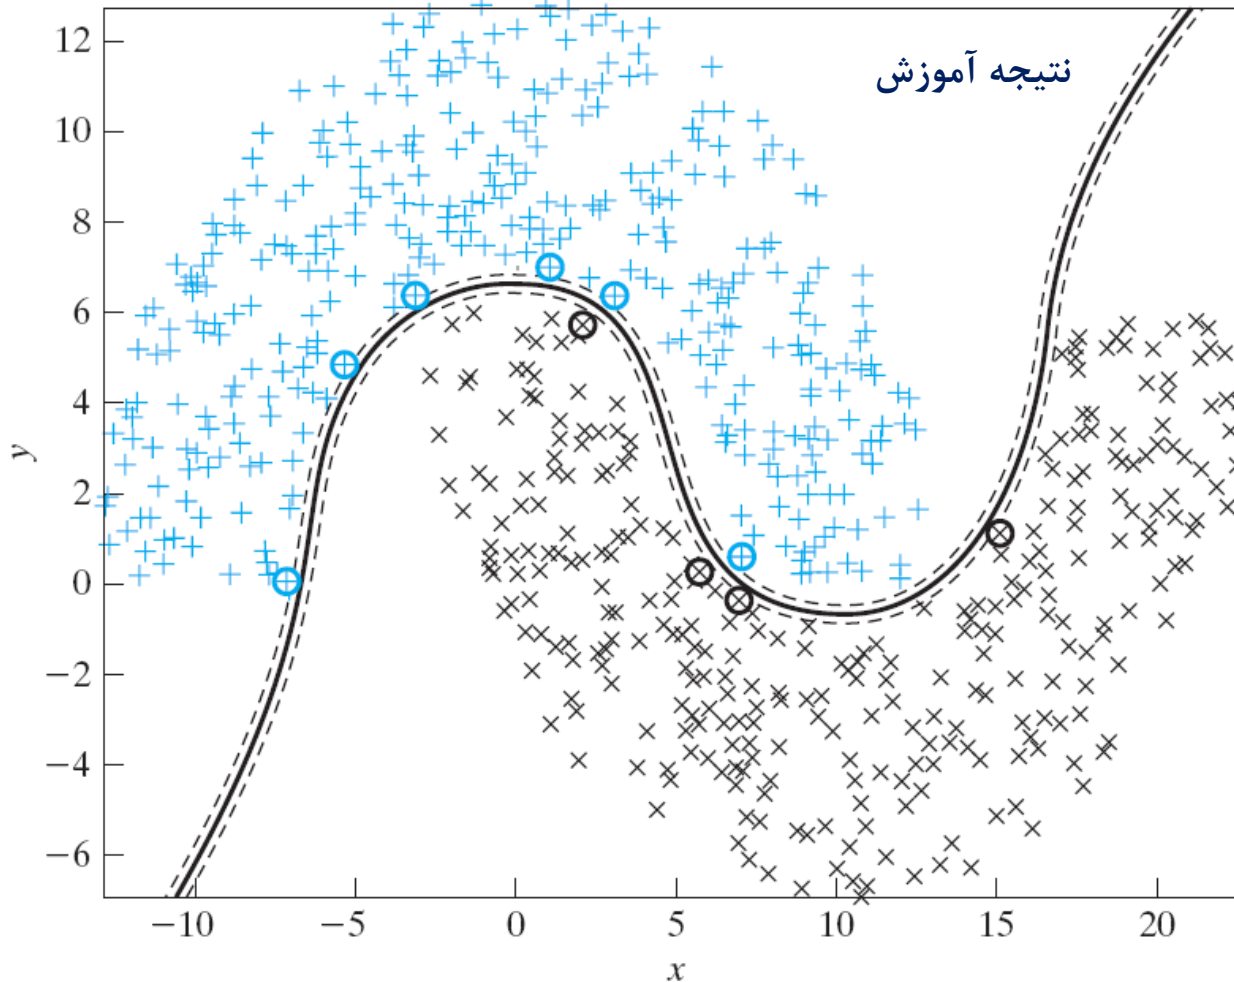
۳۰۰ داده برای آموزش
۲۰۰۰ داده برای آزمایش

$$C = \infty$$

ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل

Classification using SVM with distance = -6, radius = 10, and width = 6




۳۰۰ داده برای آموزش
۲۰۰۰ داده برای آزمایش

$$C = \infty$$

ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل

Classification using SVM with distance = -6, radius = 10, and width = 6




۳۰۰ داده برای آموزش
۲۰۰۰ داده برای آزمایش

$$C = \infty$$

ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل

Classification using SVM with distance = -6.5, radius = 10, and width = 6



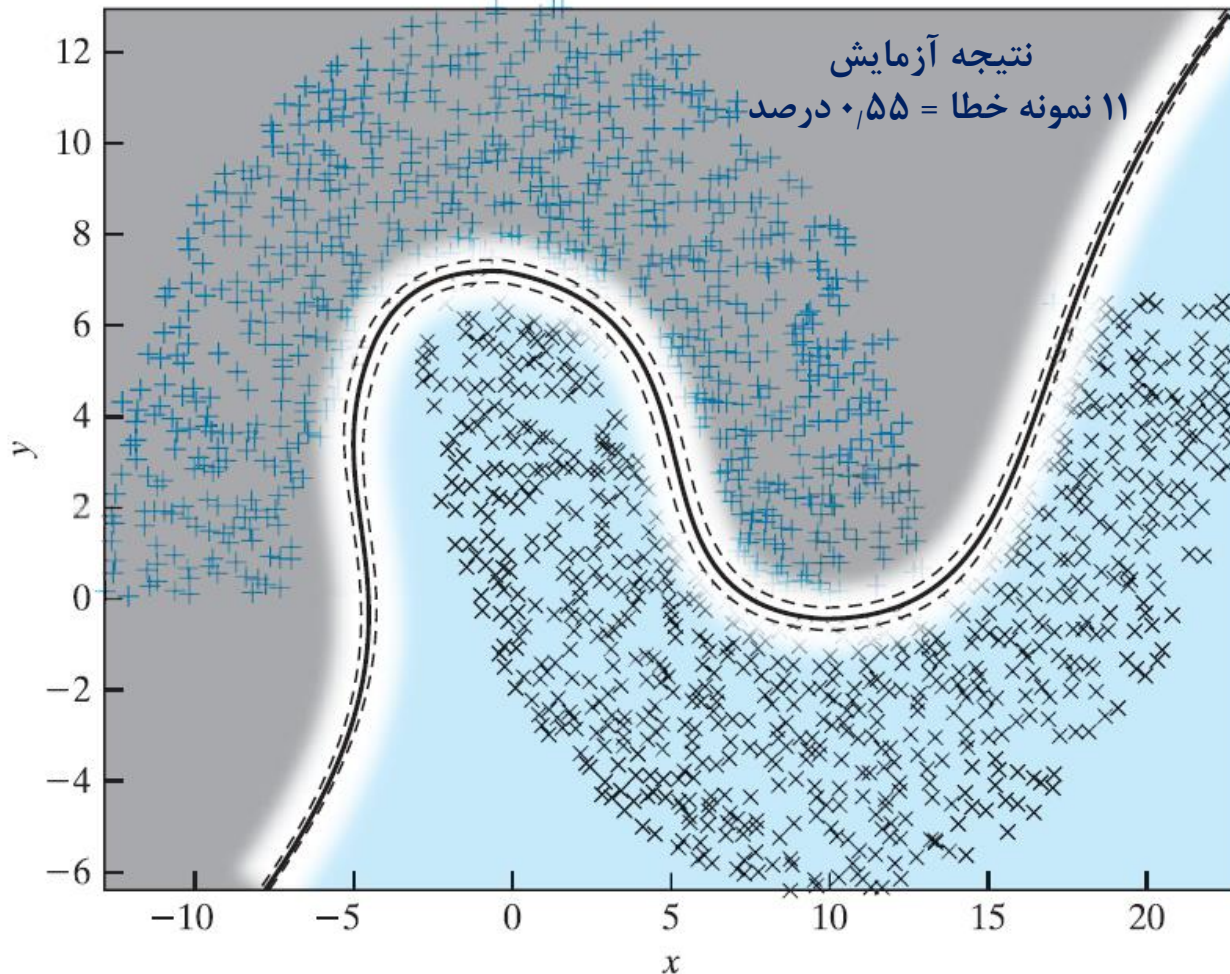
۳۰۰ داده برای آموزش
۲۰۰۰ داده برای آزمایش

$$C = \infty$$

ماشین بردار پشتیبان (SVM)

مثال: کلاسه‌بندی کلاس‌های ماه شکل

Classification using SVM with distance = -6.5 , radius = 10, and width = 6



۳۰۰ داده برای آموزش
۲۰۰۰ داده برای آزمایش

$$C = \infty$$